

Optimización de Portafolios: Markowitz, HERC, Modelización de Riesgos y Backtesting

*Evaluación Empírica y Contrastación de Modelos de Asignación de Activos (2007–
2026)*

Autor

Federico Agustín Chillón

Investigación Cuantitativa y Gestión de Portafolios

Mendoza, Argentina | Agosto de 2026

Declaración de Divulgación y Descargo de Responsabilidad

Este trabajo de investigación cuantitativa ha sido elaborado con propósitos estrictamente académicos y científicos. Los modelos analíticos, algoritmos de optimización, análisis econométricos y resultados de simulación retrospectiva (backtesting) presentados no constituyen asesoramiento financiero, consultoría de inversiones, gestión fiduciaria ni solicitud u oferta de compra o venta de instrumentos financieros, fondos cotizados (ETFs) o valores negociables. El desempeño histórico fuera de muestra no garantiza resultados futuros.

Índice General de Secciones

1. Marco Conceptual y Límites de Media-Varianza
2. Universo Multiactivo y Topología de Dependencias
3. Metodología de Modelos de Asignación
4. Modelización de Riesgo Extremo Mediante Valores Extremos (EVT)
5. Diseño Experimental y Esquema de Validación
6. Resultados Empíricos y Análisis Comparativo
7. Comportamiento en Regímenes de Crisis y Conclusiones
8. Limitaciones del Estudio
9. Referencias Bibliográficas

Resumen

Se evalúa el desempeño fuera de muestra de siete modelos de asignación de activos sobre un universo multiactivo líquido entre 2007 y 2026. La comparación abarca carteras clásicas de media-varianza (Markowitz y Markowitz Remuestreado por Bootstrap), modelos orientados a la asimetría de pérdidas de cola (Mínimo CVaR y Mínimo CDaR) y el algoritmo de Asignación Jerárquica de Contribución de Riesgo Equitativo (HERC). El marco de análisis incorpora un protocolo Walk-Forward con deriva diaria de precios, costos de transacción de 5 puntos básicos, cuantificación de pérdidas extremas mediante Teoría de Valores Extremos (Pareto Generalizada), Validación Cruzada Combinatoria con Embargo (CPCV), y contrastación de significancia con Probabilistic Sharpe Ratio (PSR) y Deflated Sharpe Ratio (DSR). HERC mantiene una diversificación efectiva ($N_{\text{eff}} = 6.46$) con una rotación anual del 31.43% frente al 288.75% de Markowitz MVO, conteniendo los retrocesos de capital durante episodios de tensión en los mercados.

Palabras clave: Asignación de activos, HERC, Markowitz, Teoría de Valores Extremos, Validación Cruzada Combinatoria, Probabilistic Sharpe Ratio.

Clasificación JEL: C58, C61, G11, G14. *MSC (2020):* 91G10, 90C90, 62P05.

Marco Conceptual y Límites de Media-Varianza

La asignación de capital en media-varianza (Markowitz, 1952) optimiza la función de utilidad cuadrática sobre el vector de rendimientos esperados μ y la matriz de covarianza poblacional Σ con un coeficiente de aversión al riesgo $\gamma = 2.5$, valor que representa el perfil estándar de una gestión moderada en asignación multiactivo.

Los parámetros μ y Σ deben inferirse a partir de series finitas de precios. Michaud (1989) demostró que el estimador muestral traslada y amplifica los errores de estimación hacia los pesos óptimos, produciendo carteras concentradas en pocos activos y sujetas a rebalanceos con alta rotación.

A su vez, la varianza penaliza desviaciones positivas y negativas con la misma magnitud, supuesto que subestima la probabilidad de pérdidas extremas cuando los rendimientos exhiben asimetría negativa y colas pesadas.

Para estabilizar el cómputo de la matriz de covarianza, se emplea el estimador de contracción lineal de Ledoit y Wolf (2004), que combina la matriz muestral S con un objetivo de correlación constante F .

El objetivo es elegir λ de modo que el estimador de contracción sea lo más cercano posible a la verdadera covarianza en promedio cuadrático: $\Sigma_{\text{hat}}(\lambda) = (1 - \lambda) S + \lambda T$, con S la matriz muestral y T la matriz objetivo (por ejemplo, la identidad o una correlación constante).

La regla se obtiene minimizando la pérdida esperada en norma de Frobenius: $L(\lambda) = E[\|\Sigma_{\text{hat}}(\lambda) - \Sigma\|_F^2]$, donde $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$. Esta norma mide la raíz cuadrada de la suma de todos los cuadrados de las entradas de la matriz.

Resolviendo esta minimización, el nivel óptimo de contracción es $\lambda^* = \beta^2 / (\delta^2 + \beta^2)$, con $\beta^2 = \|\Sigma - T\|_F^2$ y $\delta^2 = E[\|S - \Sigma\|_F^2]$. En palabras: si el ruido muestral es alto, se asigna más peso a la matriz objetivo T ; si T está lejos de la verdad, se asigna más peso a la covarianza muestral S .

Universo Multiactivo y Topología de Dependencias

El universo se compone de 9 fondos cotizados (ETFs) con liquidez diaria continua entre enero de 2007 y agosto de 2026 ($T = 4.928$ ruedas):

- Renta Variable EE.UU.: SPY (S&P 500) y QQQ (Nasdaq 100).

- Renta Variable Mercados Emergentes: EEM (MSCI Emerging Markets).
- Bienes Raíces e Infraestructura: VNQ (Vanguard Real Estate).
- Renta Fija Soberana EE.UU.: TLT (Tesoro 20+ Años) e IEF (Tesoro 7–10 Años).
- Renta Fija Corporativa Grado de Inversión: LQD (iShares Investment Grade Corporate Bond).
- Metales Preciosos: GLD (SPDR Gold Shares).
- Materias Primas: DBC (Invesco DB Commodity Index Tracking Fund).

La correlación de rendimientos ρ_{ij} se proyecta al espacio métrico angular $d_{ij} = \sqrt{0.5 * (1 - \rho_{ij})}$. La matriz de distancias D satisface los axiomas métricos euclidianos. Sobre D se aplica agrupamiento aglomerativo con criterio de Ward, minimizando la varianza interna de cada grupo. Las filas y columnas de la matriz de correlación se ordenan según las ramas del árbol jerárquico.




Figura 1. Dendrograma de agrupamiento jerárquico de activos bajo enlace de Ward y matriz de correlación reordenada. (etiquetas ajustadas por legibilidad)

Metodología de Modelos de Asignación

Las siete estrategias operan bajo restricciones de posiciones largas ($w_i \geq 0$) y presupuesto unitario ($\sum w_i = 1$).

Asignación 1/N y Cartera 60/40

La cartera 1/N fija $w_i = 1/9$ en cada fecha de rebalanceo. La cartera 60/40 mantiene $w_{SPY} = 0.60$ e $w_{IEF} = 0.40$.

Markowitz Media-Varianza

Optimiza la utilidad cuadrática ($\gamma = 2.5$) a partir del vector de rendimientos medios anualizados y la matriz Σ_{LW} .

Markowitz Remuestreado por Bootstrap

Se generan $B = 25$ muestras bootstrap con reemplazo. Para cada muestra b , se calculan (μ_b, Σ_b) , se resuelve el vector de pesos óptimos y se promedian las soluciones.

Mínimo Valor en Riesgo Condicional (CVaR)

La minimización del CVaR al cuantil 95% (Rockafellar y Uryasev, 2000) se formula como un problema de programación lineal con variables auxiliares.

Mínimo Retroceso Condicional Acumulado (CDaR)

El modelo de Chekhlov, Uryasev y Zabarankin (2005) optimiza la trayectoria acumulada de pérdidas respecto a los máximos históricos de riqueza. Sea $W_t(w)$ el retorno acumulado y $M_t(w)$ el valor máximo alcanzado hasta el instante t . El retroceso o drawdown en el período t se define como $D_t(w) = M_t(w) - W_t(w) \geq 0$. El CDaR(95%) representa la media del 5% de las peores caídas acumuladas, resuelto mediante programación lineal con variables auxiliares sobre los excesos de pérdida.

Asignación Jerárquica de Contribución de Riesgo Equitativo (HERC)

A diferencia de HRP (López de Prado, 2016) que aplica una bisección recursiva mecánica, HERC (Raffinot, 2017, 2018) preserva la estructura topológica de los clusters definidos por el enlace de Ward. En cada bifurcación entre dos clusters C_1 y C_2 , el capital se distribuye en proporción inversa a la volatilidad agregada de cada grupo. Dentro de cada cluster, las ponderaciones individuales se determinan por paridad inversa a su varianza ($1 / \sigma_i^2$), logrando un balance de riesgo sin requerir la inversión de matrices de covarianza completas.




Figura 2. Frontera eficiente media-varianza analítica (Panel A) y cono de incertidumbre muestral bajo remuestreo bootstrap de Michaud (Panel B). (etiquetas ajustadas por legibilidad)

Modelización de Riesgo Extremo Mediante Valores Extremos

La cuantificación de eventos de cola se realiza mediante el método de excesos sobre el umbral (Peaks Over Threshold, POT). Fijado el umbral u en el cuantil 90% de las pérdidas diarias, la distribución condicional de excesos converge a la ley de Pareto Generalizada (GPD), obteniendo analíticamente VaR(99%) y CVaR(99%) asintóticos.




Figura 3. Densidad empírica de rendimientos diarios y ajuste de Pareto Generalizada (GPD) en la cola izquierda de pérdidas extremas para HERC. (etiquetas ajustadas por legibilidad)

Diseño Experimental y Esquema de Validación

La evaluación empírica se estructura en tres componentes:

Análisis Walk-Forward Fuera de Muestra

El protocolo de evaluación implementa un esquema Walk-Forward con ventana de estimación rodante de 756 ruedas (3 años) y rebalances mensuales (cada 21 ruedas). Entre rebalances, las ponderaciones efectivas varían según los rendimientos diarios de mercado. En cada fecha de rebalanceo, se descuenta una comisión de 5 puntos básicos (0.05%) sobre el volumen total rotado, modelando el diferencial promedio de compra-venta (spread bid-ask) de los ETFs de la cartera.

Validación Cruzada Combinatoria con Purga y Embargo

La serie temporal se divide en $N = 6$ bloques, evaluando las 15 combinaciones de prueba fuera de muestra (López de Prado, 2018). Se impone un embargo de 10 ruedas tras cada partición para evitar sesgos por persistencia de volatilidad. Markowitz Remuestreado se evalúa en simulación rodante y se omite en CPCV por tiempo de cómputo.

Significancia Estadística: PSR y DSR

El Probabilistic Sharpe Ratio (PSR; López de Prado, 2014) evalúa la probabilidad de que el ratio de Sharpe poblacional supere a cero, corrigiendo por asimetría y exceso de curtosis. El Deflated Sharpe Ratio (DSR; López de Prado, 2014) ajusta el estadístico penalizando el sesgo de selección derivado de ensayar $M = 7$ estrategias competitivas, calculando el umbral SR_o a partir del valor esperado del máximo ratio de Sharpe bajo la hipótesis nula con la constante de Euler-Mascheroni ($\gamma_E \approx 0.5772$).

Colas EVT

Retroceso Máximo / Max DD (%)	-20.86	-21.18	-39.32	-27.53	-16.29	-19.39	-21.11
CDaR 95% (%)	-14.77	-15.52	-35.61	-23.67	-12.77	-15.81	-15.35
VaR 95% Diario (%)	-0.90	-0.94	-1.74	-1.37	-0.52	-0.61	-0.72
CVaR 95% Diario (%)	-1.40	-1.47	-2.71	-2.09	-0.79	-0.97	-1.09
VaR 99% EVT (%)	-1.67	-1.77	-3.26	-2.51	-0.94	-1.17	-1.31
CVaR 99% EVT (%)	-2.36	-2.45	-4.16	-3.32	-1.22	-1.61	-1.77
Coefficiente de Asimetría	-0.55	-0.31	-0.53	-0.46	-0.17	-0.29	-0.37
Curtosis de Exceso	9.10	9.74	4.09	5.08	3.69	5.55	7.75

D.**Significancia****y****Operatividad**

PSR (vs o) (%)	99.34	99.92	98.67	99.07	99.09	97.70	99.58
DSR (%)	95.45	99.64	95.33	96.85	97.16	93.29	98.47
Rotación Anualizada (%)	0.00	0.00	288.75	479.57	66.37	261.02	31.43
Nº Efectivo de Activos (N_eff)	9.00	1.92	1.31	2.69	1.84	2.16	6.46

La asignación dinámica de capital en cada rebalanceo mensual se detalla en la Figura 5. Se observa que Markowitz MVO rota violentamente entre renta fija y variable, mientras que HERC mantiene una estructura diversificada y suave a lo largo del tiempo. Por su parte, la Figura 6 presenta las curvas de riqueza acumulada y los episodios de retroceso de capital en las crisis de 2011, 2020 y 2022. La descomposición del presupuesto de riesgo frente a la ponderación nominal se ilustra en la Figura 7.




Figura 5. Evolución temporal de la asignación de activos a lo largo de los rebalances mensuales fuera de muestra (2010--2026). (etiquetas ajustadas por legibilidad)




Figura 6. Evolución de la riqueza acumulada (base 100) y curvas de retroceso con identificación de regímenes de crisis (2010--2026). (etiquetas ajustadas por legibilidad)




Figura 7. Descomposición del presupuesto de riesgo: Ponderación de capital (w_i) frente a Contribución Marginal al Riesgo ($\%RC_i$) por activo. (etiquetas ajustadas por legibilidad)

Comportamiento en Regímenes de Crisis y Conclusiones

Durante la crisis de deuda europea (2011), el colapso por COVID-19 (2020) y el episodio estanflacionario de 2022, HERC contuvo el retroceso máximo en -21.11%, frente a -39.32% en Markowitz MVO y -28.81% en Michaud. En 2022, la correlación positiva entre bonos y acciones provocó una caída del -21.18% en la cartera 60/40, mientras que HERC mantuvo estabilidad gracias a la ponderación asignada a materias primas (DBC) y oro (GLD).

En términos de fricción operativa, Markowitz MVO genera una rotación anualizada del 288.75% y Michaud del 481.27%. HERC opera con una rotación del 31.43%, limitando el deterioro de retorno por comisiones y deslizamiento.

Markowitz concentra la cartera en $N_{eff} = 1.31$ activos efectivos. HERC distribuye el capital en $N_{eff} = 6.46$ activos efectivos, equilibrando la contribución marginal de riesgo entre grupos. El ratio de Sharpe de HERC registra significancia estadística (PSR = 99.58%, DSR = 98.65%), con un CVaR(99%) EVT diario del -1.77% frente al -4.16% de Markowitz.

Limitaciones del Estudio

El modelo asume ejecución a precios de cierre ajustados. En activos de menor profundidad de mercado (como DBC o VNQ), los costos reales intradiarios pueden superar la cota de 5 puntos básicos.

La calibración de la distribución GPD requiere un número suficiente de observaciones en la cola ($n > 50$). En períodos prolongados de baja volatilidad, los estimadores del parámetro de forma ξ pueden exhibir mayor variabilidad muestral.

El universo de 9 ETFs permanece constante durante todo el horizonte temporal con el fin de aislar las diferencias algorítmicas, sin considerar altas o bajas de activos en el tiempo.

Referencias

Chekhlov, A., Uryasev, S., & Zabarankin, M. (2005). Drawdown measure in portfolio optimization. *International Journal of Theoretical and Applied Finance*, 8(01), 13–58.

- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for selection bias, backtest overfitting, and non-normality. *The Journal of Portfolio Management*, 40(5), 94–107.
- López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *The Journal of Portfolio Management*, 42(4), 59–69.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91.
- Michaud, R. O. (1989). The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal*, 45(1), 31–42.
- Raffinot, T. (2017). Hierarchical clustering-based asset allocation. *The Journal of Portfolio Management*, 44(2), 89–99.
- Raffinot, T. (2018). The hierarchical equal risk contribution portfolio. *Financial Markets and Portfolio Management*, 32(2), 241–261.
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–42.